


AI-BOM Architecture & Schema Specification



EVIDENCE-BASED IDENTITY, TWO-TIER STORAGE & CYCLONEDX 1.6
ML-BOM

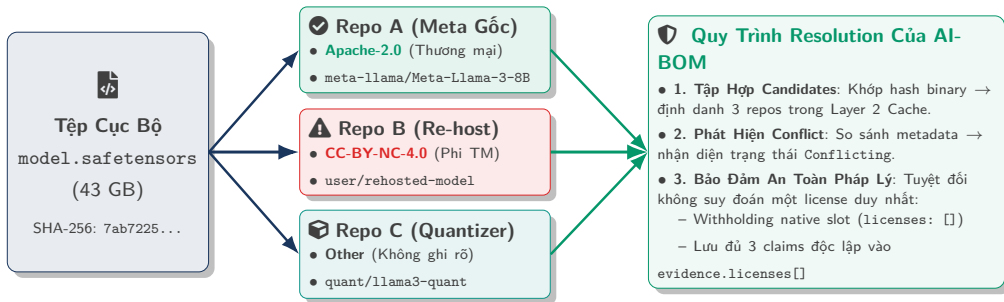
AI-BOM - SCA

Ngày 2 tháng 9 năm 2026

AI Software Bill of Materials Engine 0.1.0 · Product 5.0.0

Tổng Quan Vấn Đề & Nguyên Tắc Thiết Kế

Sơ Đồ Trực Quan: Cơ Chế Nhận Diện & Xử Lý Xung Đột Đa Repo (1-N)



💡 Nguyên Tắc An Toàn Pháp Lý

Khi phát hiện conflict bản quyền giữa các candidates của cùng một model weights, hệ thống áp dụng withholding cho native slot và lưu giữ đầy đủ claims trong evidence phục vụ kiểm toán độc lập.

Crawl Dữ Liệu Hugging Face & Cache SQLite

Số Liệu Thực Tế Khi Crawl 50.000 Models (data/poc-50k)

Chỉ số đo đạc	Dataset 20k	Dataset 50k (Hiện tại)
Tổng số Models	19,998	49,992 / 50,000
Tổng số File Hashes	268,052	798,682 hashes
File Weights	267,979	705,158 (93.85%)
Distinct Weight Sets	19,235	47,854 sets
Hash trùng đa Repo	6.10%	5.11% (max 1,037)
Repo đa nhóm Weight	57.4%	65.1% repos
Dung lượng DB L2	≈360 MB	≈ 912 MB (18 KB/model)



Nhận Xét Thực Tế

- 5.11% hash xuất hiện ở > 1 repo
→ hiện tượng trùng file là bản chất của AI Hub.
- 65.1% repo chứa > 1 nhóm weights → bắt buộc phải tách nhỏ theo từng nhóm.

📄 1. README Không Chuẩn Hóa

Tác giả nhúng toàn văn bài báo vào YAML → metadata phình to hàng chục MB văn bản phi cấu trúc.

🔗 2. File Dùng Chung Trùng Hàng Nghìn Repo

File `tokenizer.json` xuất hiện ở **1,037 repos** với 12 license khác nhau.

↔ 3. Conflict Trong Cùng 1 Repo

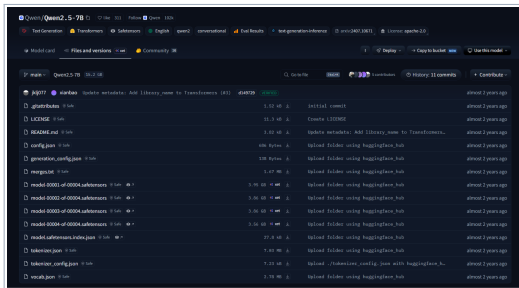
Cùng 1 model: Tags ngoài ghi Apache-2.0 nhưng Card trong ghi MIT.

📁 4. 1 Repo Chứa Nhiều Model Con

1 repo chứa 7 file GGUF quantization khác nhau (Q2, Q4, FP16).

Thực Tế Cấu Trúc Repo: Sharded Weights & Đa Nhóm GGUF

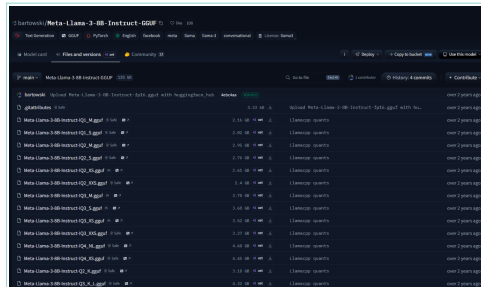
1 Model Nhiều Shards (Qwen2.5-7B)



Sharded Weights (4 Mảnh)

Model chia thành 00001 → 00004.safetensors kèm index.json.
Engine tự động gom nhóm để tính weight_set_sha256.

1 Repo Đa Nhóm Weights (LLaMA-3 GGUF)

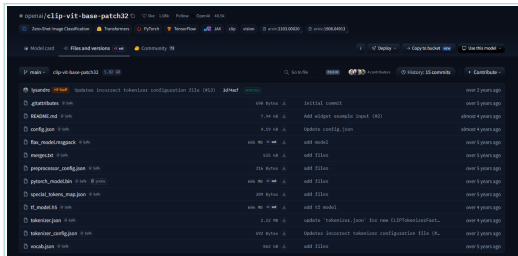


Multi-Group Withholding

Chứa > 15 phiên bản quant (IQ1, IQ2, IQ4). Engine kích hoạt withholding tại root để ngăn rò rỉ metadata sai lệch.

Thực Tế Cấu Trúc Repo: Single Model & Đa Định Dạng Weights


1 Model – 1 Repo Chuẩn Mực (CLIP)



✓ Ảnh Xạ 1–1 Tối Giản

Chỉ chứa 1 model weights duy nhất kèm cấu hình. Ảnh xạ trực tiếp 1 – 1 với component trong tài liệu CycloneDX 1.6 ML-BOM.

1 Repo Đa Định Dạng (MiniLM)

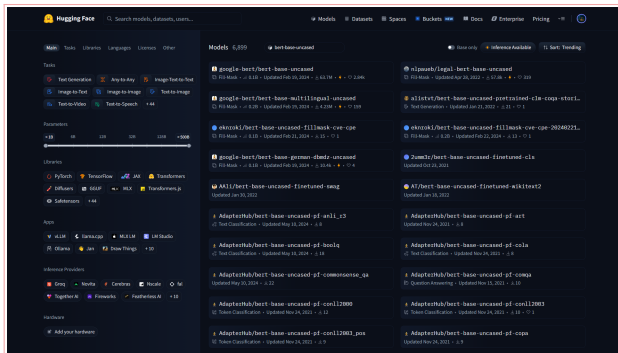


🔗 Song Song Safetensors – Bin – ONNX

Cùng 1 model nhưng có cả .safetensors, .bin, onnx/, openvino/. Engine gom nhóm theo kiến trúc tương đương.

Thực Tế Hugging Face: Bùng Nổ Biển Thề & Nhầm Lẫn Định Danh

Q 6.899 Repos Phái Sinh Khớp bert-base-uncased



⚠ Bùng Nổ Mô Hình Phái Sinh


6.899 kết quả cùng tên gốc bert nhưng:

- **Mirror / Clone:** Trùng 100% hash weights gốc.
- **File phụ:** tokenizer.json dùng chung ở 1.037 repos.
- **Finetune:** Đã sửa weights, mang hash mới.

🛡 Giải Pháp: Bắt Buộc Dùng Hash

- **Băm nhị phân:** Phân định rạch ròi Exact match vs Finetune (không đoán mò theo tên web).
- **Candidates list:** Lưu toàn bộ repo trùng hash để kiểm toán bản quyền minh bạch.

Sơ Đồ Kiến Trúc Toàn Hệ Thống (3-Layer Data Flow)



🛡️ Kiến Trúc 3 Tầng: Thu Thập – Bộ Đệm – Động Cơ Quét

Layer 1 thu thập raw JSON nội bộ $\rightarrow$ Layer 2 lập chỉ mục siêu nhẹ (≈ 18 KB/model) phân phối kèm scanner $\rightarrow$ Layer 3 quét nhị phân ngoại tuyến 100% không cần kết nối mạng.

Bộ Lọc 17 Trường Quan Trọng Từ Model Card (Allowlist)

☰ 17 Trường Cần Thiết Được Giữ Lại


Chỉ giữ đúng 17 trường có giá trị kiểm toán:

- | | |
|-----------------|----------------------|
| 1. license | 10. model_name |
| 2. library_name | 11. license_name |
| 3. pipeline_tag | 12. license_link |
| 4. tags | 13. widget |
| 5. datasets | 14. co2_eq_emissions |
| 6. metrics | 15. fine_tuned_from |
| 7. base_model | 16. thumbnail |
| 8. language | 17. model_type |
| 9. inference | |

⚡ Hiệu Quả Nén Dữ Liệu

- Loại bỏ văn bản phi cấu trúc dư thừa → dung lượng nén đạt **18.0 KB / model**.
- Toàn bộ 50.000 models lưu gọn trong **912 MB SQLite**.

Sơ Đồ Thực Thể - Quan Hệ CSDL Cache L2 (aibom.sqlite)




🔍 Tối Ưu Hóa Tốc Độ Tra Cứu (Zero-Scan Overhead)

Chỉ mục B-Tree trên cột `sha256` và `weight_set_sha256` cho phép scanner tra cứu tức thì danh tính model và candidate repos trong **dưới 1ms**, hoàn toàn độc lập với kích thước cơ sở dữ liệu.

Quy Tắc Đánh Giá Độ Tin Cậy & Xử Lý Xung Đột

Sơ Đồ Luồng Thực Thi Runtime Của aibom-core



⚙️ Quy Trình Thực Thi Khép Kín 100% Offline

Dữ liệu di chuyển tuần tự qua 7 module Rust độc lập, không chia sẻ trạng thái toàn cục, bảo đảm tính tất định và an toàn bộ nhớ.

Sơ Đồ Phân Cấp, Hòa Giải & Ví Dụ Evidence Class

🔍 Cấp 0: Heuristic

- **Đặc điểm:** Phỏng đoán từ regex / tên tệp; không có chứng thực.
- **Ví dụ:** Tệp llama-8b.gguf → phỏng đoán quy mô ~8B.

Cấp thấp nhất

🌐 Cấp 1: Declared

- **Đặc điểm:** Lời khai đơn phương trên Model Card / Web metadata.
- **Ví dụ:** README web khai: params: 8B, license: mit.

Lời khai Web

✅ Cấp 2: Verified

- **Đặc điểm:** Lời khai Web khớp cấu trúc nhị phân trong dung sai.
- **Ví dụ:** Web ghi 8B, binary đo 8.03B → thăng cấp **Verified**.

Chứng thực lời khai

📊 Cấp 3: Measured

- **Đặc điểm:** Trích xuất trực tiếp từ header binary (Ground Truth).
- **Ví dụ:** Parse header đếm đúng **8.030.261.248 params**.

Tiêu chuẩn tối cao

⚖️ Nguyên Tắc Hòa Giải (Resolution Policy)

- **Chứng thực lời khai (Cross-Validation):** Khi lời khai từ web (declared) khớp với cấu trúc nhị phân đo đạc (measured), lời khai được **thăng cấp từ Declared (1) → Verified (2)**. Số liệu nhị phân thực tế vẫn giữ vị thế tối cao (measured = 3).
- **Quyền ưu tiên cấu trúc (Structural Override):** Khi có conflict giữa khai báo và đo đạc, giá trị measured (cấp 3) luôn áp đảo lời khai declared (cấp 1) cho mọi thuộc tính vật lý.

Ví Dụ: Xử Lý Conflict Giữa Declared Metadata & Đo Đặc Thực Tế

⚠ 1. Sai Lệch Khai Báo (Model Card)

- Repo fork đổi tên model thành `super-llama-70b`.
- Model Card khai báo: `parameters: 70B`.
- File nhị phân thực tế chỉ có 6.74B params.

🛡 2. Logic Resolution Của Scanner

- Parse header tensor → xác định **6.74B params**.
- **Measured > Declared** → kết luận 6.74B vào BOM.
- Ghi log: `rejected_claim: 70B (hf_card)`.

3 Trục Đánh Giá Dữ Liệu Cốt Lõi

? 1. EvidenceClass

Mức độ tin cậy (4 cấp):

- heuristic (0)
- declared (1)
- verified (2)
- measured (3)

→ Độ xác thực của claim.

📍 2. SourceRef

Nguồn dữ liệu (6 nguồn):

- local_binary
- hf_api
- hf_card
- local_config
- derived
- heuristic

🔗 3. Resolution


Trạng thái (4 loại):

- Resolved (Rõ ràng)
- Ambiguous (Đồng thuận)
- Conflicting (Tranh chấp)
- Unknown (Chưa rõ)

i Giá Trị Tính Toán Dẫn Xuất (Derived Fields)

$\text{VRAM} = \text{params} \times 2 \text{ bytes (BF16)}$ → tính trực tiếp từ giá trị đo đạc *measured* → giữ nguyên cấp tin cậy **Measured**.

Sơ Đồ Trực Quan: Luồng Phối Hợp 3 Trục Khái Niệm Bằng Chứng



💡 Tính Độc Lập Trục Giao (Orthogonality)

SourceRef biểu thị provenance vật lý; **EvidenceClass** xác định trọng số độ tin cậy; **Resolution** là kết quả logic tất định. Tuyệt đối không đồng nhất provenance với kết luận resolution.

Ví Dụ: Tại Sao Cùng 1 Request API Lại Tách 2 Nguồn Dữ Liệu?


```
{
  "id": "user/my-model",
  // 1. NGUON hf_api: Tac gia chon tren Web Settings
  "tags": ["license:apache-2.0", "text-generation"],

  // 2. NGUON hf_card: Boc tu ruot file README.md
  "cardData": {
    "license": "mit",
    "datasets": ["c4"]
  }
}
```

⚡ Nguy Cơ Mất Dữ Liệu Nếu Gộp Nguồn

- Hugging Face **không** tự động đồng bộ 2 trường này.
- Nếu gộp chung thành 1 nguồn hf: Giá trị apache-2.0 và mit sẽ đè mất nhau.
- **Giải pháp:** Tách riêng 2 nguồn hf_api (Tags) và hf_card (README frontmatter) → Engine tự động phát hiện mâu thuẫn nội bộ.

Sơ Đồ Trực Quan: Cổng Lọc Phân Cấp FileRole (File Gate)



💡 Nguyên Tắc Cô Lập Định Danh

Chỉ có file mang vai trò **Weight** mới có quyền định danh mô hình học máy. Các file phụ trợ, hình ảnh và tệp nén bị cô lập hoàn toàn để triệt tiêu nguy cơ gán nhầm metadata trên diện rộng.

6 Tình Huống Xử Lý Thực Tế Của Thuật Toán from_claims

Tình Huống	Tập Claims Đầu Vào	Floor	Kết Quả Resolution
A. Đồng thuận	MIT (Card) + MIT (API)	heuristic	Resolved { MIT, declared }
B. Xác thực chéo	4096 (Card) + 4096 (Header đo)	heuristic	Resolved { 4096, verified }
C. Quyền ưu tiên cấu trúc	FP32 (Card) + BF16 (Header đo)	heuristic	Resolved { BF16, measured }
D. Conflict nội bộ	MIT (Card) + Apache-2.0 (API)	heuristic	Conflicting (Withholding)
E. Policy Gate lọc Heuristic	MIT (Card) + GPL (Tên phỏng đoán)	declared	Resolved { MIT, declared }
F. Không có dữ liệu	Trống 0 có claim nào	declared	Unknown

Nguyên Tắc Cốt Lõi Của Resolution

Structural Override: Kết quả đo đặc nhị phân (measured) luôn áp đảo lời khai; **Withholding:** Khi xuất hiện conflict giữa các nguồn cùng cấp độ, hệ thống không bao giờ đoán mò mà duy trì trạng thái tranh chấp.

Cách Xử Lý Khi 1 File Trùng Ở Nhiều Repo (across_candidates)



💡 Nguyên Tắc Đại Diện Đa Dạng Hóa

Khi một tệp xuất hiện ở hàng nghìn kho lưu trữ, thuật toán Round-Robin ngăn chặn hiện tượng các kho lưu trữ phổ biến áp đảo danh sách, bảo đảm mọi loại giấy phép đều có đại diện để kiểm toán viên xem xét.

12 Tình Huống Thực Tế Khi Quét Model & JSON Mẫu

Tổng Hợp 12 Case Thực Tế Khi Quét Model

Case	Tình Huống	Input Thực Tế	Trạng Thái	Hành Vi JSON Đầu Ra
1	Khớp Đơn Nhất	CLIP (model.safetensors)	Resolved	Điền đủ native slots, confidence: 1.0
2	Đồng Thuận Đa Repo	Llama 8B (safetensors → 3 mirror repos)	Ambiguous	Điền native slot licenses, candidate: 3
3	Conflict Giấy Phép	File 43GB (Repo gốc Meta vs Fork MIT)	Conflicting	Withholding native slot, ghi nhận claims
4	Auxiliary Trùng Lặp	tokenizer.json (trùng ở 1,037 repos)	Conflicting	Round-Robin 50 đại diện đủ 12 license
5	Media Ngoài Lề	logo.png (file ảnh lẫn trong repo)	Media	Chặn tạo candidate model, 0 xuất purl
6	Sharded Weights	Qwen 7B (4 shards safetensors)	Resolved	Ghép chuỗi hash, thăng cấp Verified
7	GGUF Multi-Group	Thư mục GGUF (chứa nhiều bản quant)	Multi-Group	Root sang type: "file", withholding shapes
8	File Nội Bộ	custom_bert.bin tự train (Hash Miss)	Unknown	Binary sniffer đo parameters cấp measured
9	Conflict Nội Bộ Repo	Tag Web Apache-2.0 vs README ghi MIT	Conflicting	Withholding native slot, lưu 2 claims evidence
10	Conflict Khai vs Đo	Repo 70B câu view (weights thực chất 7B)	Resolved	Quyền ưu tiên cấu trúc (Measured), log audit
11	File Weights 0-Byte	pytorch_model.bin rỗng do tải lỗi	EMPTY_SHA	Bỏ qua hash rỗng, cảnh báo tệp không hợp lệ
12	ONNX Split Data	model.onnx + các file_data_N	Resolved	Regex cắt hậu tố số → gom 1 model group

Case 1: Khớp Đơn Nhất 1-1 (Single Model Match)

Input

- **File:** model.safetensors (3.8 GB)
- **Repo:** OpenAI CLIP (1 repo duy nhất)
- **Context:** Khớp SHA-256 tuyệt đối với DB.

✓ Cách Xử Lý

Khớp SHA-256 tuyệt đối → confidence: 1.0, điền đầy đủ native slots (purl, licenses).

```
{
  "bomFormat": "CycloneDX", "specVersion": "1.6",
  "serialNumber": "urn:uuid:3e6717a6-...",
  "components": [{
    "bom-ref": "model-scan-001",
    "type": "machine-learning-model",
    "name": "Meta-Llama-3-8B", "group": "meta-llama",
    "purl": "pkg:huggingface/meta-llama/Meta-Llama-3-8B@e9149a1",
    "licenses": [{ "license": { "name": "llama3" } }],
    "evidence": {
      "identity": {
        "field": "purl", "confidence": 1.0,
        "methods": [{ "technique": "hash-comparison", "confidence": 1.0 } ]
      }
    }
  ]
}
```

Case 2: Nhiều Repo Nhưng Cùng Khai Báo (Multi-Repo Unanimous)

Input

- **File:** model.safetensors (16 GB)
- **Repo:** 3 repos mirror của Llama-3-8B.
- **Context:** Cùng tác giả Meta và license llama3.

Cách Xử Lý

Đồng thuận 100% →
Ambiguous(agreed), vẫn điền native
slot licenses, ghi nhận 3 candidates.

```
{
  "components": [{
    "bom-ref": "model-scan-002",
    "type": "machine-learning-model",
    "name": "Llama-3-8B",
    "licenses": [{"license": {"name": "llama3"}}],
    "evidence": {
      "identity": {
        "field": "purl",
        "candidateCount": 3,
        "resolution": "ambiguous",
        "agreement": true,
        "methods": [{"technique": "hash-comparison", "confidence": 1.0}]
      }
    }
  ]
}
```

Case 3: Conflict Giấy Phép Đa Repo (1–N Candidates)



Input

- **File:** consolidated.00.pth (43 GB)
- **Repo:** Trùng hash ở 3 repos khác nhau:
 - Repo A (Meta gốc): license llama3
 - Repo B (Fork re-host): tự sửa thành MIT
 - Repo C (Quantizer): ghi other
- **Context:** Tranh chấp license giữa các repo mirror.



Cách Xử Lý

Withholding native slot (licenses: []), lưu đủ 3 claims độc lập vào evidence.licenses[].

```
{
  "components": [{
    "type": "machine-learning-model", "name": "SomeModel",
    "licenses": [], // De trong do bat dong thong tin
    "evidence": {
      "identity": {
        "resolution": "conflicting", "conflicts": ["license"]
      },
      "licenses": [
        {"license": {"name": "other"}, "source": "repo-a", "downloads": 5200000},
        {"license": {"id": "MIT"}, "source": "repo-b", "downloads": 200000}
      ]
    }
  ]
}
```

Case 4: File Phụ Trùng Hàng Nghìn Repo (tokenizer.json)

Input

- **File:** tokenizer.json (1.8 MB)
- **Context:** Trùng hash ở **1,037 repos** với 12 nhóm bản quyền (MIT, Apache, GPL...).

Cách Xử Lý

Khóa trần heuristic, Round-Robin lấy 50 đại diện bảo toàn đủ 12 loại license.

```
{
  "components": [{
    "name": "tokenizer", "licenses": [],
    "evidence": {
      "identity": {
        "candidateCount": 1037,
        "resolution": "conflicting", "conflicts": ["license"]
      },
      "licenses": [
        // 50 đại diện Round-Robin can bang từ 12 nhóm license
        {"license": {"id": "Apache-2.0"}, "source": "repo-1"},
        {"license": {"id": "MIT"}, "source": "repo-2"},
        {"license": {"id": "GPL-3.0"}, "source": "repo-3"}
        // Bao phủ đầy đủ 12 nhóm license
      ]
    }
  ]
}
```

Case 5: File Ảnh, Icon Không Phải Model (logo.png)

Input

- **File:** logo.png hoặc banner.jpg (300 KB)
- **Context:** Trùng ở 352 repos (file media ngoài lề).

Cách Xử Lý

Nhận diện `FileRole::Media` → Chặn tạo model candidate, chỉ xuất component type: "file".

```
{
  "components": [{
    "bom-ref": "file-scan-005",
    "type": "file",
    "name": "huggingface_logo.png",
    "hashes": [{
      "alg": "SHA-256",
      "content": "def456..."
    }]
    // Không gán purl và modelCard
    // Tu chời suy diễn sai danh tính model
  }]
}
```

Case 6: Thư Mục Chứa Sharded Weights

Input


- **Folder:** models/Qwen2.5-7B/
- **Files:**
 - model-00001-of-00004.safetensors (4.8 GB)
 - model-00002-of-00004.safetensors (4.8 GB)
 - model-00003-of-00004.safetensors (4.8 GB)
 - model-00004-of-00004.safetensors (1.2 GB)
 - config.json
- **Context:** Model lớn bị cắt thành 4 shards.

Cách Xử Lý

Sắp xếp lexicographical → ghép hash
→ tính weight_set_sha256 khớp đúng
model group.

```
{
  "metadata": {
    "component": {
      "type": "machine-learning-model",
      "name": "Meta-Llama-3-8B",
      "purl": "pkg:huggingface/meta-llama/Meta-Llama-3-8B@e9149a1"
    }
  },
  "components": [{
    "modelCard": {
      "modelParameters": {
        "architecture": "LlamaForCausalLM",
        "parameters": 8030000000 // Dat cap Verified qua cross-verify
      }
    }
  ]
}
```

Ví Dụ Trực Quan: Cách Gom Nhóm & Tính Chữ Ký Sharded Weights



✓ Tính Tất Định Tuyệt Đối (Determinism)

Cho dù hệ điều hành (Windows NTFS, Linux ext4, macOS APFS) liệt kê file theo thứ tự nào, bước **Lexicographical sort** đảm bảo chuỗi băm RAW luôn giống nhau → Chữ ký `weight_set_sha256` trùng khớp byte-for-byte trên mọi hệ thống.

Case 7: Thư Mục Chứa Nhiều Bản Quantization (GGUF Multi-Group)

Input

- **Folder:** Meta-Llama-3-8B-GGUF/
- **Files:**
 - llama-3-8b-Q4_K_M.gguf (4.9 GB)
 - llama-3-8b-Q8_0.gguf (8.5 GB)
 - llama-3-8b-Q2_K.gguf (3.2 GB)
 - config.json (**chỉ ghi shape FP16 gốc!**)
- **Context:** 1 thư mục chứa nhiều bản quant khác nhau.

Cách Xử Lý

Root chuyển sang type: "file", đưa thông số model vào withheld, tách các sub-components.

```
{
  "metadata": {
    "component": {
      "type": "file", // Chuyển từ machine-learning-model
      "name": "my_models_dir"
    }
  },
  "properties": [
    {"name": "aibom:withheld", "value": "architecture,param_count,context_length"}
  ]
  // 7 cum model con duoc mo ta doc lap trong envelope report/2
}
```


Ví Dụ Trực Quan: Xử Lý Thư Mục 7 Bản Quantization GGUF (Multi-Group)

📁 **Thư Mục my_models/**

- ├ llama-3-q2_k.gguf (4 GB, Q2)
- ├ llama-3-q4_k_m.gguf (6 GB, Q4)
- ├ llama-3-q8_0.gguf (10 GB, Q8)
- ├ ... (tổng cộng 7 bản quant)
- └ config.json (**Ghi shape FP16!**)

⊗ **Nguy Cơ Áp Nhầm Config**

- Nạp config.json vào root
- Gán thông số FP16 (32 GB VRAM) cho cả file Q2_K (chỉ cần 4 GB VRAM)
- → **Sai lệch thông số phần cứng!**

🛡️ **Giải Pháp Cách Ly AI-BOM**

- Root chuyển thành type: "file"
 - Withholding shape chung vào withheld
 - Tách 7 bản GGUF thành **7 components con**
- với thông số đo đạc độc lập!

🛡️ **Nguyên Tắc An Toàn Metadata**

Khi một thư mục chứa nhiều model có cấu hình khác nhau, tuyệt đối không cho phép file cấu hình ngoài (như config.json) áp đặt thuộc tính chung lên toàn bộ thư mục.

Case 8: File Chưa Từng Được Crawl (File Nội Bộ)

Input

- **File:** custom_bert.safetensors (1.2 GB)
- **Context:** Model nội bộ tự train, hash không có trên Hugging Face (Hash Miss).

Cách Xử Lý

resolution: unknown, binary sniffer
parse header đo chính xác params &
dtype ở cấp **Measured**.

```
{
  "components": [{
    "type": "machine-learning-model",
    "name": "unknown-model",
    "modelCard": {
      "modelParameters": {
        "parameters": 6738415616, // Do trực tiếp từ header (Measured)
        "dataType": "BF16" // Do trực tiếp từ header (Measured)
      }
    },
    "evidence": {
      "identity": {"resolution": "unknown"}
    }
  }]
}
```

Case 9: Conflict Nội Bộ Repo (API Tags vs README)

Input

- **File:** model.safetensors từ user/my-model.
- **Context:** Conflict nội bộ repo:
 - Web UI Tags (hf_api): Ghi Apache-2.0
 - File README.md (hf_card): Ghi MIT

Cách Xử Lý

Withholding native slot, lưu giữ cả 2 claims độc lập vào evidence.licenses[].

```
{
  "components": [{
    "name": "my-model", "licenses": [],
    "evidence": {
      "identity": {"resolution": "conflicting", "conflicts": ["license"]},
      "licenses": [
        {"license": {"id": "Apache-2.0"}, "source": "hf_api", "class": "declared"},
        {"license": {"id": "MIT"}, "source": "hf_card", "class": "declared"}
      ]
    }
  ]
}
```

Case 10: Conflict Giữa Declared Metadata & Đo Đặc Cấu Trúc

Input

- **File:** model.safetensors (13.5 GB)
- **Repo:** Fork user/super-llama-70b
- **Model Card:** Khai param_count: 70B
- **Context:** Tác giả khai 70B câu view, weights thực tế chỉ 7B.

Cách Xử Lý

Structural Override: Sniffer đếm đúng 6.74B params → Chốt 6.74B (Measured), đưa 70B vào audit log.

```
{
  "components": [{
    "modelCard": {
      "modelParameters": {
        "parameters": 6738415616 // Chốt theo kết quả đo lường
      }
    },
    "properties": [
      // Lỗi khai 70B bị loại và lưu vào audit log
      {"name": "aibom:audit.rejected_claim", "value": "param_count:70B (hf_card)"}
    ]
  }]
}
```

Case 11: Xử Lý File Weights 0-Byte Không Hợp Lệ

Input

- **File:** `pytorch_model.bin` (0 bytes)
- **Context:** File hỏng do rớt mạng khi tải (SHA rỗng `e3b0c44...`).

Cách Xử Lý

Loại trừ `EMPTY_SHA256` → Không gán candidate model, cảnh báo tệp rỗng không hợp lệ.

```
{
  "metadata": {
    "component": {"type": "file", "name": "empty_model_dir"}
  },
  "properties": [
    {
      "name": "aibom:warning",
      "value": "No valid weight files found. Directory does not identify a model."
    }
  ]
}
```

Case 12: File ONNX Kèm Các File Phân Tách Ngoài

Input

- **Folder:** gemma-4-onnx/
- **Files:**
 - model.onnx (500 KB, graph)
 - model.onnx_data_1 (2 GB, weights)
 - model.onnx_data_2 (2 GB, weights)
- **Context:** Chuẩn ONNX tự tách graph và tensor weights thành files ngoài.

Cách Xử Lý

Regex cắt hậu tố số → tự động gom 245 files split (332 GB) vào 1 model group duy nhất.

```
{
  "components": [{
    "type": "machine-learning-model",
    "name": "gemma-4-onnx",
    "properties": [
      {"name": "aibom:weight_set_sha256", "value": "a1b2c3..."},
      {"name": "aibom:group_members", "value":
        "model.onnx,model.onnx_data_1,model.onnx_data_2"}
    ]
  }]
}
```

Cấu Trúc JSON Đầu Ra: Chuẩn Quốc Tế & Nội Bộ

Cấu Trúc Định Dạng Envelope (report/2)



Đặc Điểm Tầng Envelope

- **Kiến trúc phân tầng:** Tầng ngoài bọc metadata kiểm toán nội bộ (report/2), tầng trong tích hợp payload CycloneDX 1.6.
- **Quản lý nhóm trọng số:** Mảng groups[] theo dõi từng cụm weights cùng chữ ký weight_set_sha256.
- **Truy xuất nguồn gốc:** Trường provenance ghi nhận tường minh nguồn gốc của từng thuộc tính.
- **Đánh giá chất lượng:** completeness_score đo lường độ hoàn thiện metadata theo 40 chỉ tiêu kỹ thuật.

```
{
  "schema": "opswat.aibom.report/2",
  "engine_version": "0.1.0",
  "scan_target": "/data/models/Meta-Llama-3-8B",
  "scan_timestamp": "2026-09-01T12:00:00Z",
  "deterministic": true,
  "completeness_score": 0.92,
  "groups": [{
    "group_name": "Meta-Llama-3-8B-Weights",
    "weight_set_sha256": "4a7d8b2e1f9c3a0b...",
    "member_count": 4,
    "total_bytes": 16060522496,
    "resolution": "resolved",
    "candidates": [
      "pkg:huggingface/meta-llama/Meta-Llama-3-8B@e9149a1"
    ],
    "provenance": {
      "license": "hf_card",
      "param_count": "local_binary",
      "architecture": "local_config"
    }
  ]},
  "cyclonedx": { /* CycloneDX 1.6 ML-BOM Payload */ }
```


Ví Dụ: Payload Chuẩn CycloneDX 1.6 ML-BOM

✓ Đặc Điểm Chuẩn Hóa


- **Định danh tất định:** Trường `serialNumber` sinh theo RFC 9562 UUIDv8, bảo đảm tính nhất quán byte-for-byte.
- **Toàn vẹn khóa liên kết:** `metadata.component` không gán `bom-ref` nhằm tránh xung đột khóa định danh.
- **Độ tin cậy định danh:** Đạt mức `confidence: 1.0` tuyệt đối qua đối chiếu mã băm SHA-256.
- **Thuộc tính mở rộng:** Tích hợp thông số đo đặc nhị phân (`lms:*`) và trạng thái lượng tử hóa (`aibom:*`).

```
{
  "bomFormat": "CycloneDX", "specVersion": "1.6",
  "serialNumber": "urn:uuid:3e6717a6-2009-8786-9051-7f888eb1a57e",
  "components": [{
    "bom-ref": "model-artifact-root", "type": "machine-learning-model",
    "name": "Meta-Llama-3-8B",
    "purl": "pkg:huggingface/meta-llama/Meta-Llama-3-8B@e9149a1",
    "licenses": [{ "license": { "name": "llama3" } }],
    "modelCard": {
      "modelParameters": {
        "architectureFamily": "llama",
        "parameters": 8030261248 // Measured
      }
    },
    "evidence": {
      "identity": {
        "field": "purl", "confidence": 1.0,
        "methods": [{ "technique": "hash-comparison", "confidence": 1.0 } ]
      }
    },
    "properties": [
      { "name": "aibom:quantization", "value": "BF16"},
      { "name": "lms:param_count", "value": "8030261248" }
    ]
  }]
}
```

Type 2 & Đánh Giá Thực Nghiệm

Sơ Đồ Trực Quan: Cấu Trúc File Nhị Phân & Quét 2 Giai Đoạn

Tập Trọng Số Nhị Phân 40 GB Trên Bộ Nhớ Lưu Trữ (model.safetensors)



💡 Tối Ưu Hóa Tài Nguyên & Độ Chính Xác

Tách biệt giữa **trích xuất thuộc tính hình thái** (chỉ đọc header trong < 5ms) và **định danh mật mã học** (tính SHA-256 theo luồng đệm mà không nạp toàn bộ ma trận trọng số vào bộ nhớ).

☰ Kết Quả Test Suite


Thực thi tự động qua kịch bản acceptance.ps1:

1. **Workspace Tests:** 366/366 tests thành công (0 fail, 0 skip).
2. **Corpus Assertions:** Kiểm chứng trên 49,992 mô hình, lược đồ DDL 40 cột.
3. **Tính Tất Định:** Đảm bảo tính nhất quán byte-for-byte giữa các lần quét.
4. **CycloneDX 1.6:** Vượt qua 100% tiêu chuẩn JSON Schema quốc tế.
5. **Kiểm Soát Hồi Quy:** 8 bài test chuyên biệt ngăn ngừa lỗi hồi quy cho các ca biên.
6. **Chất Lượng Mã Nguồn:** 0 cảnh báo linter (cargo clippy -D warnings).

🕒 Đánh Giá Hiệu Năng

- Truy vấn mã băm SQLite: < 1 ms.
- Trích xuất header (tệp 40 GB): < 5 ms.
- Mức chiếm dụng RAM runtime: < 50 MB.
- Tái tạo dữ liệu ngoại tuyến: Xử lý 50.000 mô hình trong vài phút mà không cần kết nối mạng.

Tổng Kết: Toàn Cảnh Kiến Trúc & Chuẩn Đầu Ra AI-BOM



Chi Tiết Lược Đồ CSDL Ngoại Tuyển (aibom.sqlite)

📊 Bảng model (40 Cột Chuẩn Hóa)

```
CREATE TABLE model (  
  repo_id TEXT PRIMARY KEY,  
  author TEXT, model_name TEXT, sha TEXT,  
  pipeline_tag TEXT, library_name TEXT,  
  model_type TEXT, model_architecture TEXT,  
  license_spdx TEXT,  
  license_name TEXT, -- Lưu license gốc (D36)  
  license_link TEXT, -- Link điều khoản (D36)  
  downloads INTEGER, likes INTEGER,  
  config_json TEXT, card_data_json TEXT,  
  weight_set_count INTEGER,  
  weight_file_count INTEGER,  
  total_weight_bytes INTEGER  
  -- Tổng cộng 40 cột cho 49.992 models  
);
```

📊 Bảng model_file & weight_set

```
CREATE TABLE model_file (  
  repo_id TEXT, path TEXT,  
  sha256 TEXT, -- B-Tree Index (<1ms)  
  lfs_sha256 TEXT, size_bytes INTEGER,  
  role TEXT, -- weight/config/doc...  
  PRIMARY KEY (repo_id, path)  
);  
  
CREATE TABLE weight_set (  
  weight_set_sha256 TEXT PRIMARY KEY,  
  repo_id TEXT, member_count INTEGER,  
  total_bytes INTEGER  
);
```

🔍 Chỉ Mục Tối Ưu Tốc Độ

B-Tree Index trên sha256 → Tra cứu danh tính 1 file < 1ms cho 798.682 files.

✅ Đặc Tính Kiến Trúc: 100% Offline, Gọn Nhẹ & Tất Định

Toàn bộ 49.992 mô hình được nén gọn trong **912 MB SQLite** (18 KB/model), nhúng trực tiếp dạng tệp cục bộ, không cần cài đặt database server riêng và tái lập 100% không cần mạng.



Thảo Luận & Q&A

AI-BOM Architecture & Schema Specification · Version 0.1.0